

הסתברות - תרגיל 3

(1) נתון, X ו- Y משתנים אקראיים בלתי תלויים. $P(X=x) = \frac{1}{2}$ ו- $P(Y=y) = \frac{1}{2}$.
השאלה:

$$P(X|Y) = \frac{P(Y|X) \cdot P(X)}{P(Y)}$$

$$P(Y|X) = P(Y=1|X) + P(Y=-1|X)$$

:הנני מנסה להבין מה זה אומר

$$\arg \max_{y=\{1, -1\}} P(X|Y) \cdot P(Y) = \arg \max_{y=\{1, -1\}} \frac{P(Y|X) \cdot P(X)}{P(Y)} \cdot P(Y)$$

$$= \arg \max_{y=\{1, -1\}} P(Y|X) \cdot P(X) = \arg \max_{y=\{1, -1\}} (P(Y=1|X) + P(Y=-1|X)) \cdot P(X)$$

כלומר, נרצה למצוא את ה- y שמקסימלי

$$P(Y=-1|X) < \frac{1}{2} \quad \text{או} \quad P(Y=1|X) \geq \frac{1}{2}$$

אם $P(Y=1|X) \geq \frac{1}{2}$ אז $P(Y=1|X) > P(Y=-1|X)$ ולכן $y=1$ הוא המינימום.
אם $P(Y=-1|X) > \frac{1}{2}$ אז $P(Y=-1|X) > P(Y=1|X)$ ולכן $y=-1$ הוא המינימום.

$$\arg \max_{y=\{1, -1\}} (P(Y=1|X) + P(Y=-1|X)) \cdot P(X) = 1$$

כלומר, $P(Y=-1|X) \geq \frac{1}{2}$ או $P(Y=1|X) < \frac{1}{2}$, נרצה למצוא את ה- y שמקסימלי

$$\arg \max_{y=\{1, -1\}} (P(Y=1|X) + P(Y=-1|X)) \cdot P(X) = -1$$

כלומר, $P(Y=1|X) < \frac{1}{2}$ או $P(Y=-1|X) \geq \frac{1}{2}$, נרצה למצוא את ה- y שמקסימלי

$$\arg\max_{y=\{1,2\}} \delta_y(x) = \arg\max_{y=\{1,2\}} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln p(y) \quad (2)$$

הפרמטר μ_y הוא הממוצע של x עבור y

$$p(y) = f_Y(y) = \frac{f_{X|Y}(x|y)}{f_X(x)}$$

הפרמטר Σ

$$= \arg\max_{y=\{1,2\}} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln \left(\frac{f_{X|Y}(x|y)}{f_X(x)} \right)$$

הפרמטר Σ

$$= \arg\max_{y=\{1,2\}} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln(f_X(x)) + \ln(f_{Y|X=x}(y)) - \ln(f_{X|Y=y}(x))$$

הפרמטר Σ הוא הממוצע של x עבור y

$$= \arg\max_{y=\{1,2\}} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln(f_{Y|X=x}(y)) - \ln(f_{X|Y=y}(x))$$

הפרמטר Σ הוא הממוצע של x עבור y

$$= \arg\max_{y=\{1,2\}} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln(f_{Y|X=x}(y)) - \ln \left(\frac{1}{\sqrt{\Sigma}} \exp \left\{ -\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) \right\} \right)$$

הפרמטר Σ הוא הממוצע של x עבור y

$$= \arg\max_{y=\{1,2\}} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln(f_{Y|X=x}(y)) + \frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y)$$

$$= \arg\max_{y=\{1,2\}} \ln(f_{Y|X=x}(y)) + x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \left(\frac{1}{2} x^T \Sigma^{-1} x - \frac{1}{2} \mu_y^T \Sigma^{-1} x \right)$$

$$= \arg\max_{y=\{1,2\}} \ln(f_{Y|X=x}(y)) + x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \frac{1}{2} x^T \Sigma^{-1} x - \frac{1}{2} \mu_y^T \Sigma^{-1} x$$

ההנחה, $\frac{1}{2} x^T \Sigma^{-1} x$ וכן

$$= \arg \max_{y \in \{+1\}} \ln(f_{y|x=x}(y)) + \frac{1}{2} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} x$$

הנה Σ^{-1} היא מטריצה סימטרית

$$= \arg \max_{y \in \{+1\}} \ln(f_{y|x=x}(y)) + \frac{1}{2} x^T \Sigma^{-1} \mu_y - \frac{1}{2} x^T \Sigma^{-1} \mu_y$$

$$= \arg \max_{y \in \{+1\}} \ln(f_{y|x=x}(y))$$

לכן \ln היא פונקציה מונוטונית

$$= \arg \max_{y \in \{+1\}} P(y|x) = \arg \max_{y \in \{+1\}} P(x|y) \cdot P(y) = h_0$$

ההנחה

ההנחה

הנחה

(3) ההנחה $P(y)$ היא ההסתברות, $P(x|y)$ היא ההסתברות $P(y)$ היא ההסתברות $P(x|y)$ היא ההסתברות

$$\hat{\mu}_{+1} = \frac{1}{|S_{+1}|} \cdot \sum_{i \in S_{+1}} x_i \quad ; \quad \hat{\mu}_{-1} = \frac{1}{|S_{-1}|} \cdot \sum_{i \in S_{-1}} x_i$$

ההנחה $\hat{\mu}_{+1}$ היא ההסתברות $\hat{\mu}_{-1}$ היא ההסתברות

$$\hat{\Sigma} = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$$

ההנחה $\hat{\Sigma}$ היא ההסתברות $\hat{\Sigma}$ היא ההסתברות

$$p = \frac{|S_{+1}|}{m}$$

ההנחה p היא ההסתברות p היא ההסתברות

(4) כעת נרצה למצוא את המרחק המינימלי בין המישור למקור. נסמן את המרחק המינימלי ב- d .

המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .
 המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .
 המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .
 המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .
 המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .

(5) נרצה למצוא את המרחק המינימלי בין המישור למקור. נסמן את המרחק המינימלי ב- d .

המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .
 המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .
 המרחק המינימלי הוא המרחק מהמקור למישור. נסמן את המרחק המינימלי ב- d .

$$\argmin_{(w,b)} \|w\|^2 \text{ s.t. } \forall_i, y_i(\langle w, x_i \rangle + b) \geq 1$$

$$= \argmin_{(w,b)} (w \ b) I_n \begin{pmatrix} w \\ b \end{pmatrix} \text{ s.t. } \begin{bmatrix} x_1 y_1 & 1 \\ \vdots & \vdots \\ x_m y_m & 1 \end{bmatrix} \begin{pmatrix} w \\ b \end{pmatrix} \geq \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$$

נרצה למצוא את המרחק המינימלי בין המישור למקור. נסמן את המרחק המינימלי ב- d .

$$= \argmin_{(w,b)} \frac{1}{2} (w \ b) \begin{pmatrix} V^T \\ Q \end{pmatrix} \begin{pmatrix} w \\ b \end{pmatrix} + \frac{a}{n} \begin{pmatrix} V \\ a \end{pmatrix}$$

$$\text{s.t. } \underbrace{\begin{bmatrix} -x_1 y_1 & -1 \\ \vdots & \vdots \\ -x_m y_m & -1 \end{bmatrix}}_A \underbrace{\begin{pmatrix} w \\ b \end{pmatrix}}_V \leq \underbrace{\begin{pmatrix} -1 \\ \vdots \\ -1 \end{pmatrix}}_b$$

(6) נניח, $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה. נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה. נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה.

נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה. נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה. נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה.

$$\xi_i \geq \max \{0, 1 - y_i \langle w, x_i \rangle\}$$


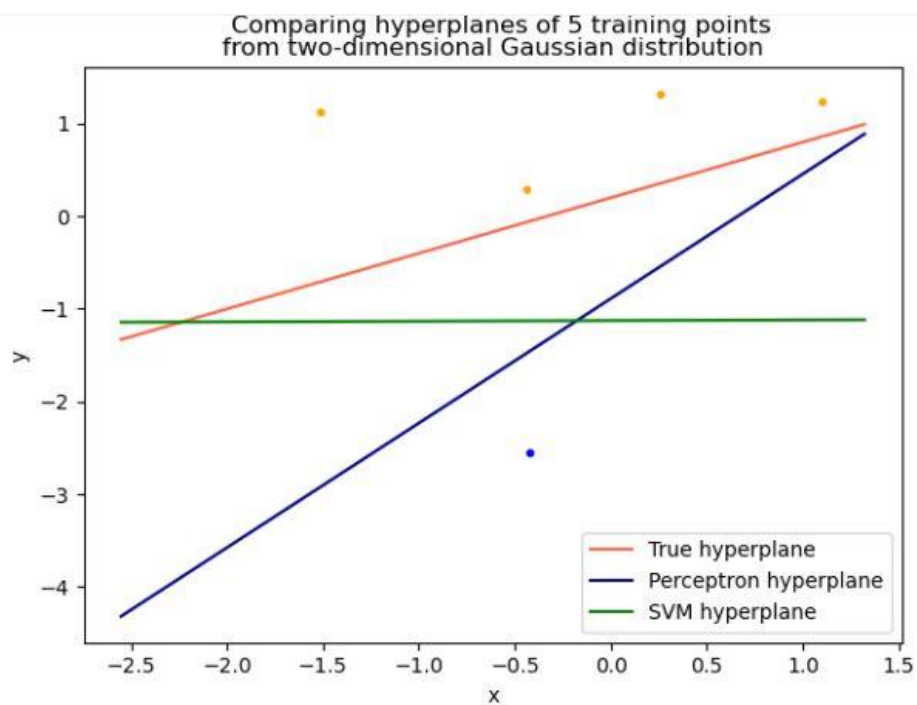
נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה. נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה. נניח גם $\xi_i \geq 0$ הוא סך הריבועים של המרחק מהשורה i למישור ההפרדה.

$$\arg \min_{(w)} \frac{1}{2} \|w\|^2 + \frac{1}{m} \sum_{i=1}^m \text{hinge}(a)$$


.ערב

מערכות לומדות – המשך תרגיל בית 3


(9)




Comparing hyperplanes of 15 training points
from two-dimensional Gaussian distribution



Comparing hyperplanes of 25 training points
from two-dimensional Gaussian distribution




Comparing hyperplanes of 70 training points from two-dimensional Gaussian distribution




(10

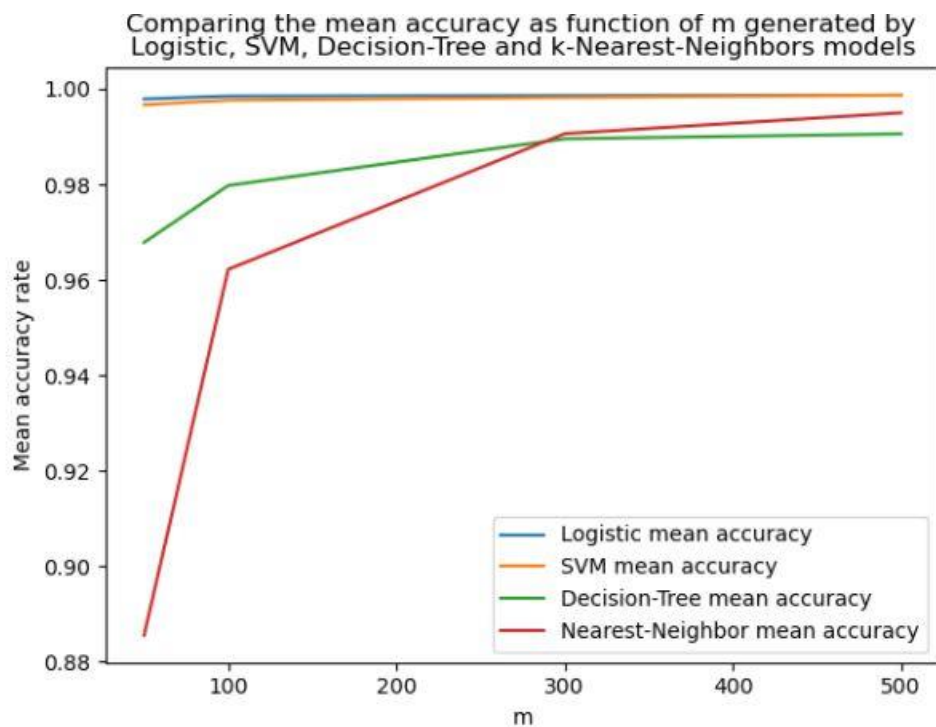
Comparing the mean accuracy as function of m generated by Perceptron, SVM and LDA models



(11) המסווג בעל התוצאות הטובות ביותר הוא מסווג SVM עבור ערכי m -ה שנקבעו אך עם זאת נראה שעבור m מספיק גדול, המסווג מסוג Perceptron מתכנס אליו בעוד שהמסווג מסוג LDA נותר הרבה מאחור ברמת הדיוק שלו מה שמעורר את השאלה עבור איזה m נתחיל לראות אותו מתכנס לאחרים. אני חושב שהשוני ביניהם נובע מכך שהמסווג מסוג SVM לוקח בחשבון שלו גם את השוליים (margins) עבור טעויות ולכן למעשה מוסיף נדבך שמדויק את התוצאות שלו עוד יותר. בהמשך אליו, המסווג מסוג Perceptron מהווה מתחרה טוב שכן הדאטה שאנו עובדים איתו ניתן להפרדה לינארית. לעומת זאת, וכפי שלמדנו, המסווג מסוג LDA מניח הנחות מקדימות על ההתפלגות ממנה הגיעו הנקודות וכן על מטריצת השונות המשותפות ולכן, כאשר איננו יכולים באמת להניח זאת על הדאטה בו השתמשנו נקבל תוצאה שאינה מדויקת.

(12)





מדידת זמני ריצה:

עבור $m = 50$:

0.3725855 = Logistic

1.8642795 = SVM

0.4754824 = Decision Tree

3.1184359 = KNearest Neighbors

עבור $m = 100$:

0.8059226 = Logistic

2.2935955 = SVM

0.40316 = Decision Tree

11.2997653 = KNearest Neighbors

עבור $m = 300$:

1.343318 = Logistic

3.1968263 = SVM

0.5366957 = Decision Tree

32.4929515 = KNearest Neighbors

עבור $m = 500$:

1.7737247 = Logistic

4.0327846 = SVM

1.1298895 = Decision Tree

68.4276903 = KNearest Neighbors